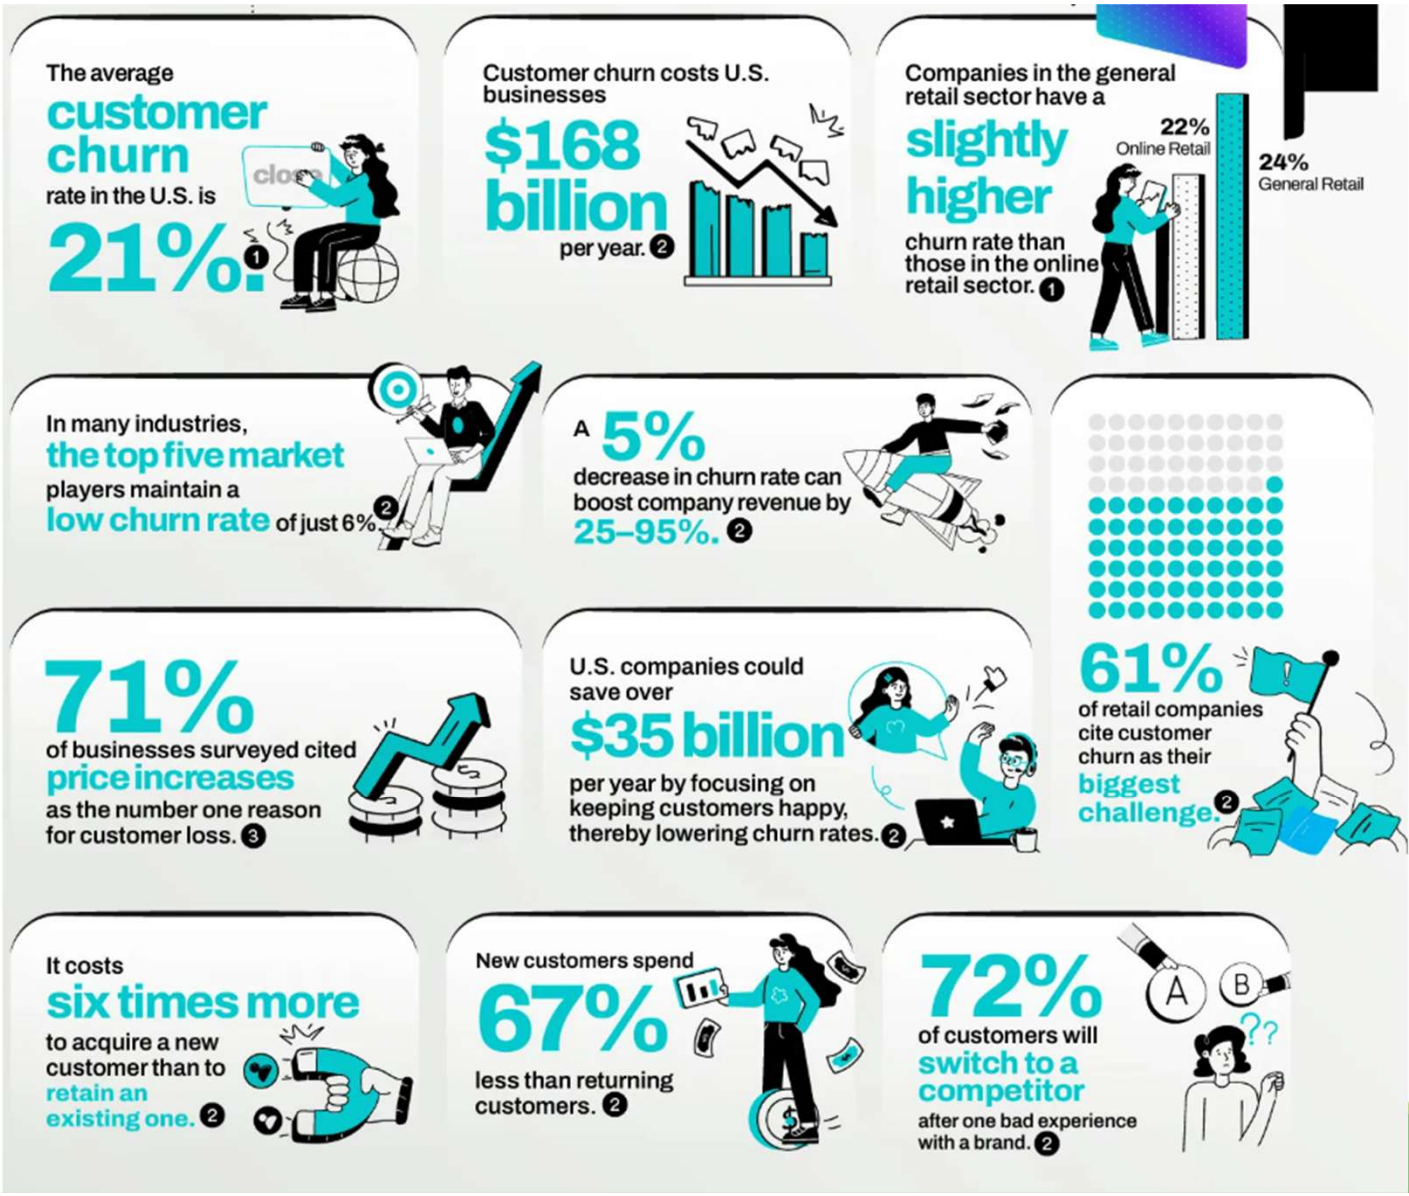
Customer Churn

- Es el porcentaje de clientes que dejan de usar un producto o servicio en un tiempo fijo.
- Se dividen los clientes perdidos entre los clientes que había al inicio, y el resultado se multiplica por 100.

$$\text{Churn} = \left(\frac{\text{Clientes perdidos en el período}}{\text{Clientes al inicio del período}} \right) \times 100$$

- Si tenía 10 clientes al inicio del periodo y perdí 2, tengo una tasa de perdida de:
  - (2 / 10) * 100 = **20%**



Fórmula CLV

$$CLV = \frac{(ARPU \times margen) \times r}{(1 + d - r)} - CAC$$

La tasa multiplicativa: (1 + d - r)

- Esta expresión se utiliza en modelos dinámicos o de proyecciones financieras para calcular el **factor de cambio** de la base de clientes de un período a otro.

- Esta fórmula no cuenta cabezas de clientes; sirve para **calcular el Valor de Vida del Cliente (Customer Lifetime Value o CLV) a largo plazo**. Es decir, ayuda a calcular cuanto dinero dejará un cliente en total antes de que decida irse para siempre.

Impacto de la Perdida o Retención a largo plazo
Ejemplo sencillo..

Periodo	Número de Clientes iniciales	Tasa de Retención	Clientes restantes
0	100	95%	95
1	95	95%	90
2	90	95%	86
3	86	95%	82

Dado que el CLV es una métrica a largo plazo, la retención-perdida de clientes debe de analizarse a largo plazo considerando factores tales cómo el valor de dinero en el tiempo, para evaluar el impacto el día de **hoy**.

Breakout Room # 1 – Palanca “r” vs AOV

Diríjase con su grupo a su breakout room, y siga las instrucciones en “breakout_2.ipynb”, una vez terminadas reporte sus resultados de la comparación CLV.

Objetivo:

- Comparar el valor de aumentar la “Palanca r”, la retención vs. el AOV (Average Order Value) de los clientes.
- ¿Quién ganara?
  - ¿Cuál escenario subió más el CLV, y por cuánto?
  - ¿Por qué el mismo esfuerzo (+10% en un número, +5 puntos en el otro) produce resultados tan distintos?
  - Si tuvieran que elegir UNA iniciativa para el próximo trimestre, una campaña de venta cruzada (sube el AOV) o un programa de retención (sube r), ¿con cuál se van, y por qué, visto el multiplicador?

La retención no es una palanca lineal

Cuánto vale un cliente, en meses de margen, según su retención mensual

Retención mensual	Multiplicador	Cambio
70%	2,3×	—
80%	3,8×	+65%
85%	5,3×	+39%
90%	8,2×	+55%
95%	15,8×	+93%
97%	24,3×	+54%

Multiplicador = r / (1 + d − r), con d = 1% mensual

Subir el AOV promedio un 10%

Sube el CLV un 10%

AOV = Average Order Value

Subir la retención de 90% a 95%

Lo sube un 93%

LA PREGUNTA DE HOY

Si la retención es la palanca más poderosa, ¿cómo la movemos?

Y sobre todo: ¿cómo sabemos que la movimos nosotros, y no que esos clientes iban a quedarse igual?

Churn contractual y churn no contractual

CONTRACTUAL

Netflix, el gimnasio, tu operador

El cliente **cancela**. Hay una fecha, un evento, un registro en la base de datos.

El churn es un dato que se observa.

NO CONTRACTUAL

Starbucks, el supermercado, Amazon

El cliente **simplemente deja de aparecer**. Nadie cancela un café.

El churn es algo que se debe definir cuidadosamente

Un cliente que lleva 60 días sin venir, ¿se fue o está de viaje? **No hay forma de saberlo con certeza.** Por eso BG/NBD: no clasifica vivo o muerto, estima una **probabilidad** de seguir activo.

Definir el churn es una decisión de negocio

No es un parámetro técnico. Cambia a quién se va a contactar y cuánto se va a gastar.

Si defines churn como...	Clientes marcados	Qué te pasa
30 días sin comprar	Muchísimos	Persigues a gente que solo se fue de vacaciones. Gastas de más.
90 días sin comprar	Un número razonable	Equilibrio habitual en retail de alta frecuencia. (Starbucks)
180 días sin comprar	Pocos	Llegas tarde. Cuando lo detectas, ya se fue de verdad.

Definición de Ventana - regla práctica

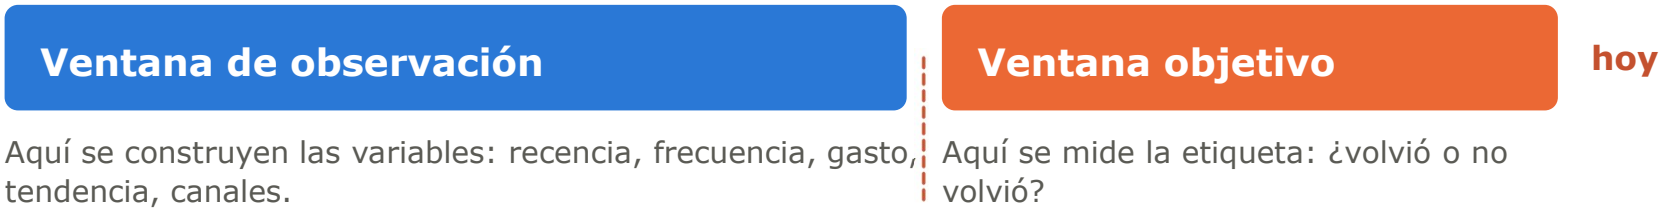
La ventana debe ser un múltiplo del ciclo de compra típico. Si nuestros clientes compran cada semana, 90 días son 13 ciclos perdidos: **demasiado**.

Por segmento, no global

Un "Daily Commuter" ausente 14 días ya es alarma. Un "Weekend Commuter" ausente 14 días es normal. **Una sola ventana para todos mezcla los dos casos.**

Las dos ventanas

El error número uno en un modelo de churn es dejar que el futuro se filtre al pasado



La fuga de información más común: usar la recencia medida al final de la ventana objetivo. Un cliente que compró ayer obviamente va a comprar: el modelo da AUC de 0,98 y no sirve para nada, porque en producción esa variable no existe todavía.

Tres familias de modelo

Regresión logística

Predice la probabilidad de churn en la ventana.

Pros: los coeficientes se explican a un director. Rápida y estable.

Cons: no captura interacciones sin que se escriban a mano.

Árboles y boosting

XGBoost, LightGBM, Gradient Boosting.

Pros: más certeros con datos tabulares. Casi sin preparación.

Cons: caja negra; necesita SHAP para explicarse.

Análisis de supervivencia

Cox, modelos de hazard, BG/NBD.

Pros: responde *cuándo*, no solo *si*. Maneja bien a quien aún no se ha ido.

Cons: más difícil de montar y de explicar.

Los tres responden la misma pregunta: **¿quién se va a ir?** Ninguno responde la que de verdad importa para gastar presupuesto, y eso es lo que vamos a ver ahora.

Cómo se evalúa un modelo de churn

El accuracy es inútil aquí, y conviene entender por qué

Si el 8% de tus clientes se va, un modelo que diga **"no se va nadie"** acierta el 92% de las veces. Accuracy 0,92 y cero valor.

Métrica	Qué responde	Cuándo la usas
AUC / ROC	¿Ordena bien a los clientes por riesgo?	Comparar modelos entre sí
Precision@k	De los k que marqué, ¿cuántos se fueron de verdad?	Cuando el presupuesto solo alcanza para k
Recall	De los que se fueron, ¿a cuántos detecté?	Cuando perder un cliente es muy caro
Lift en el decil 1	¿Cuántas veces mejor que elegir al azar?	Explicárselo a negocio

Precision@k es la métrica honesta cuando hay presupuesto limitado, porque obliga a decir cuántos clientes vas a poder contactar antes de medir nada.

Breakout Room # 2 – Calcular el Churn

Diríjase con su grupo a su breakout room, y siga las instrucciones, una vez terminadas reporte sus resultados del churn.

Objetivo:

- Detectar a los clientes que están en riesgo de perderse.
- ¿Lograremos retenerlos?
  - ¿Qué AUC les dio el modelo correcto? ¿Y el que hace trampa?
  - En una frase: ¿por qué un AUC de 1.0 (o casi) es una mala noticia y no una buena?
  - Anoten cuántos clientes marcaron como "alto riesgo" (prob > 70%). Vamos a preguntar: "¿a quién contactamos?“ , con esta lista en la mano, ¿cuál es su respuesta?

HASTA AQUÍ, TODO BIEN

Tenemos un modelo de churn con AUC 0,99. Tenemos presupuesto para contactar al 30%.

Contactemos a los de mayor riesgo.

Es lo que hace casi todo el mundo. Y es exactamente donde se pierde el dinero.

La pregunta que falta

Mandamos la campaña a María. María volvió a comprar. ¿Funcionó?

LO QUE VIMOS EN EL MODELO

María recibió la oferta y volvió.

Lo anotamos como una conversión. El reporte dice que la campaña funcionó.

LO QUE NECESITABAS SABER

¿Habría vuelto igual sin la oferta?

Si la respuesta es sí, le regalaste $5 y anotamos un éxito que no existió.

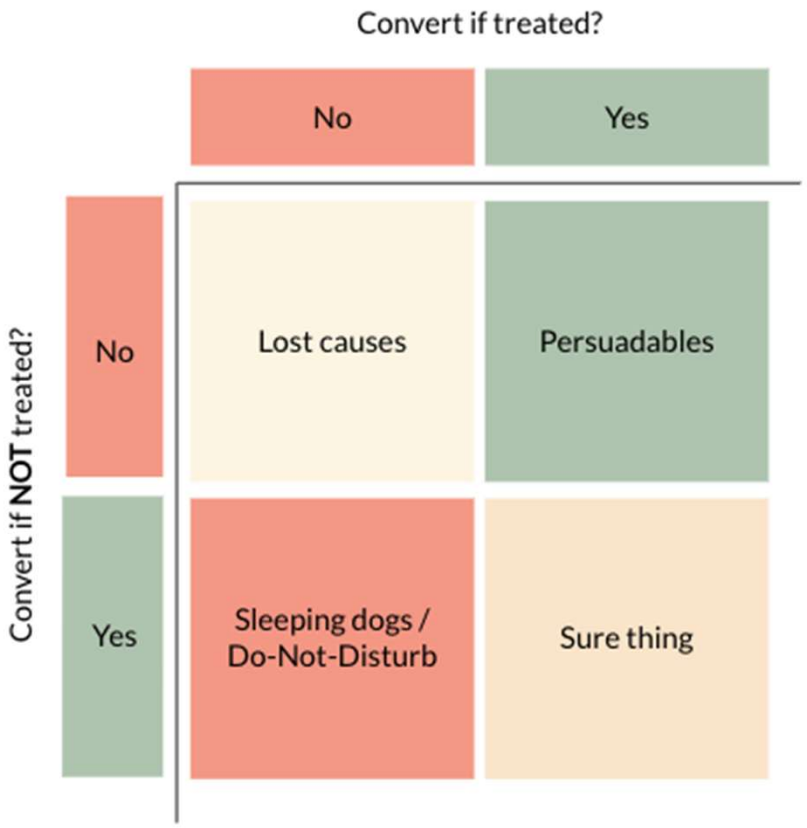
Eso que te falta se llama contrafactual

Es el mismo cliente, en el mismo momento, sin haber recibido nada. No existe y no se puede observar. Toda la inferencia causal consiste en construir una aproximación creíble de ese universo paralelo.

Un modelo de churn dice quién se va a ir.

Nunca dice a quién se puede retener.

Son dos preguntas distintas, y confundirlas cuesta el presupuesto entero.

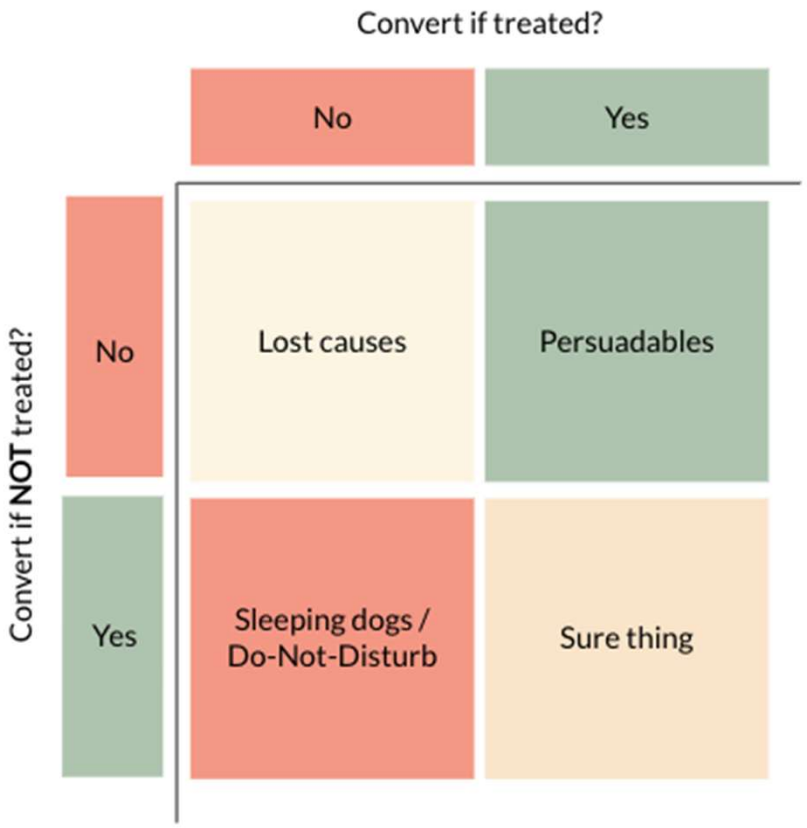


4 tipos de clientes

3. Los Perros Dormidos (*Sleeping Dogs* o *Do Not Disturb*)

Es el grupo más peligroso. Son clientes que están tranquilos o conformes, pero **si los contactas, generas el efecto contrario al deseado** (se molestan, recuerdan que querían cancelar el servicio o se dan de baja).

- **Con campaña:** No compran (o abandonan la marca).
- **Sin campaña:** Compran (o se quedan quietos pagando el servicio).
- **Estrategia: Evitarlos a toda costa.** El contacto desencadena una respuesta negativa. Un ejemplo clásico es el cliente que tiene una suscripción olvidada y, al recibir un correo de la empresa, se acuerda de cancelarla.

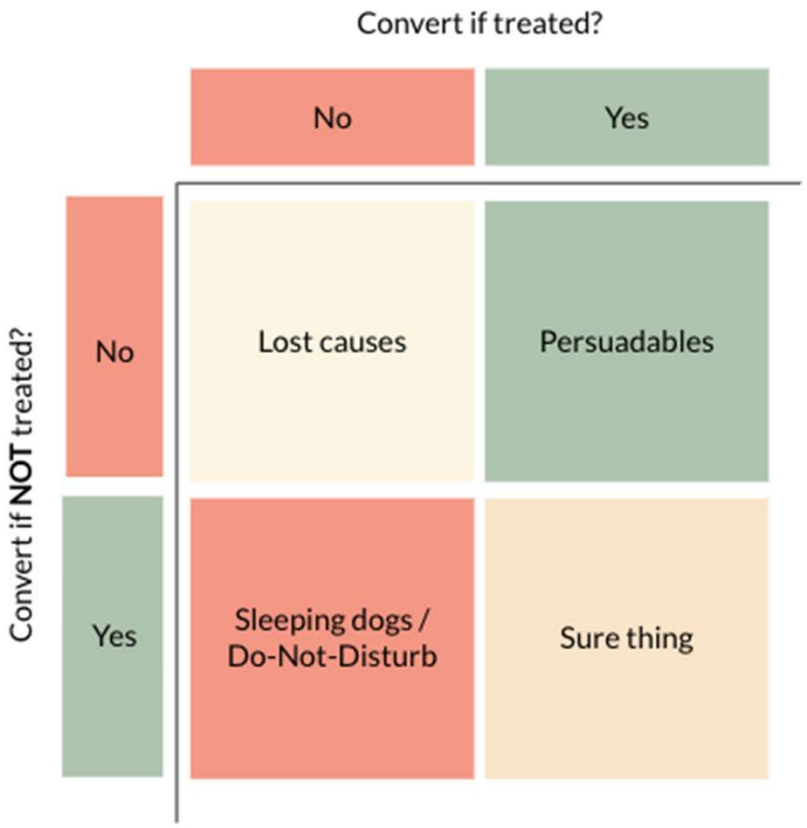


4 tipos de clientes

2. Los Persuadibles (*Persuadables*)

Este es el grupo más importante y el verdadero **objetivo de cualquier campaña de marketing**. Son clientes que solo reaccionarán si se les da un empujón.

- **Con campaña:** Compran.
- **Sin campaña:** No compran.
- **Estrategia: Concentrar todos los esfuerzos de la campaña en ellos.** Aquí es donde la publicidad genera un valor real y un retorno de inversión (*ROI*) directo, ya que la campaña es la que causa la venta

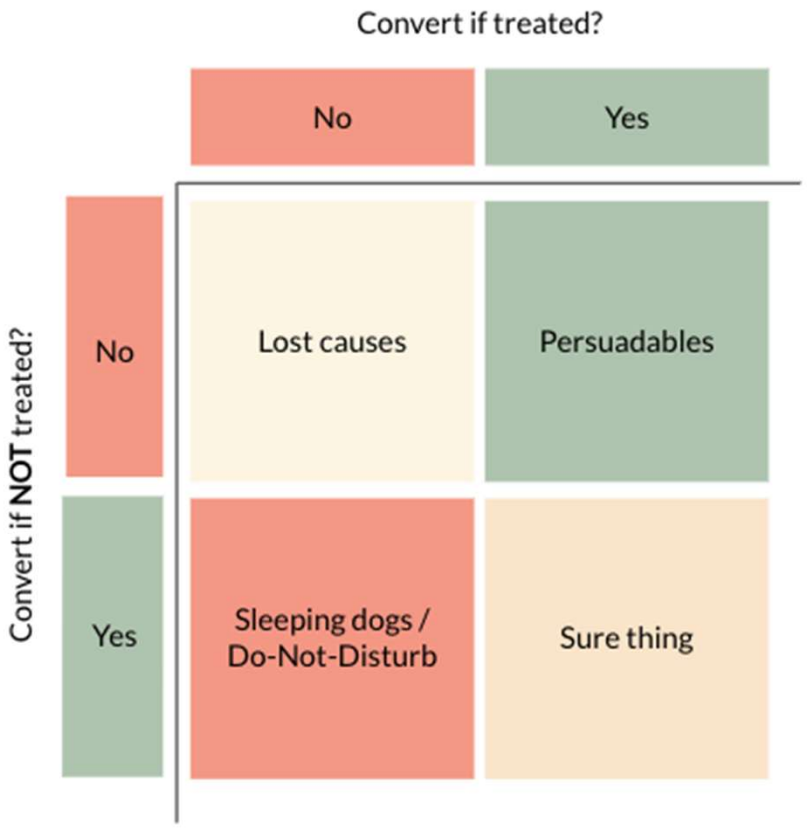


4 tipos de clientes

1. Las Causas Perdidas (*Lost Causes*)

Son aquellos clientes que **no van a comprar (o renovar) de ninguna manera**, independientemente de si reciben la campaña o no.

- **Con campaña:** No compran.
- **Sin campaña:** No compran.
- **Estrategia: No gastar dinero en ellos.** Dirigirles publicidad es un desperdicio de presupuesto porque su respuesta siempre será negativa.



4 tipos de clientes

4. Una Cosa Segura (*Sure Things*)

Son los clientes que ya están convencidos y **van a comprar de todos modos**, reciban o no la publicidad. Su lealtad o necesidad actual es alta.

- **Con campaña:** Compran.
- **Sin campaña:** Compran.
- **Estrategia: No gastar presupuesto de campaña en ellos.** Aunque verlos comprar se siente como un éxito, enviarles ofertas o descuentos solo reduce el margen de ganancia de la empresa, ya que habrían pagado el precio completo de igual manera.

Tus clientes son de cuatro tipos

SIN campaña: compra	SIN campaña: no compra	CON campaña: compra
Sure Things Iban a comprar igual. Les regalas el descuento. **Uplift 0 · No contactar**	**Persuadables** Vuelven solo si los contactas. El único grupo que deja dinero. **Uplift positivo · CONTACTAR**	**CON campaña: no compra**
Sleeping Dogs Compraban, y contactarlos los espanta. **Uplift NEGATIVO · Jamás contactar**	**Lost Causes** Ya se fueron. No hay oferta que los traiga. **Uplift 0 · No contactar**	

Un modelo de churn ve alto riesgo en Lost Causes y en Sleeping Dogs: los dos grupos a los que no hay que escribir

Uplift

- En marketing, el **uplift** (o incremento) es el aumento real en las ventas o en un resultado medible que ocurre gracias a una campaña o acción publicitaria, en comparación con lo que habría pasado sin ella.
- Un cliente puede tener alta probabilidad de comprar y, al mismo tiempo, uplift CERO, porque iba a comprar de todos modos (ese es el "Sure Thing")
- También puede tener uplift NEGATIVO , contactarlo reduce su probabilidad de comprar (el "Sleeping Dog")
- Entonces uplift no mide "qué tan probable es que compre", mide "qué tan probable es que MI ACCIÓN cambie el resultado"

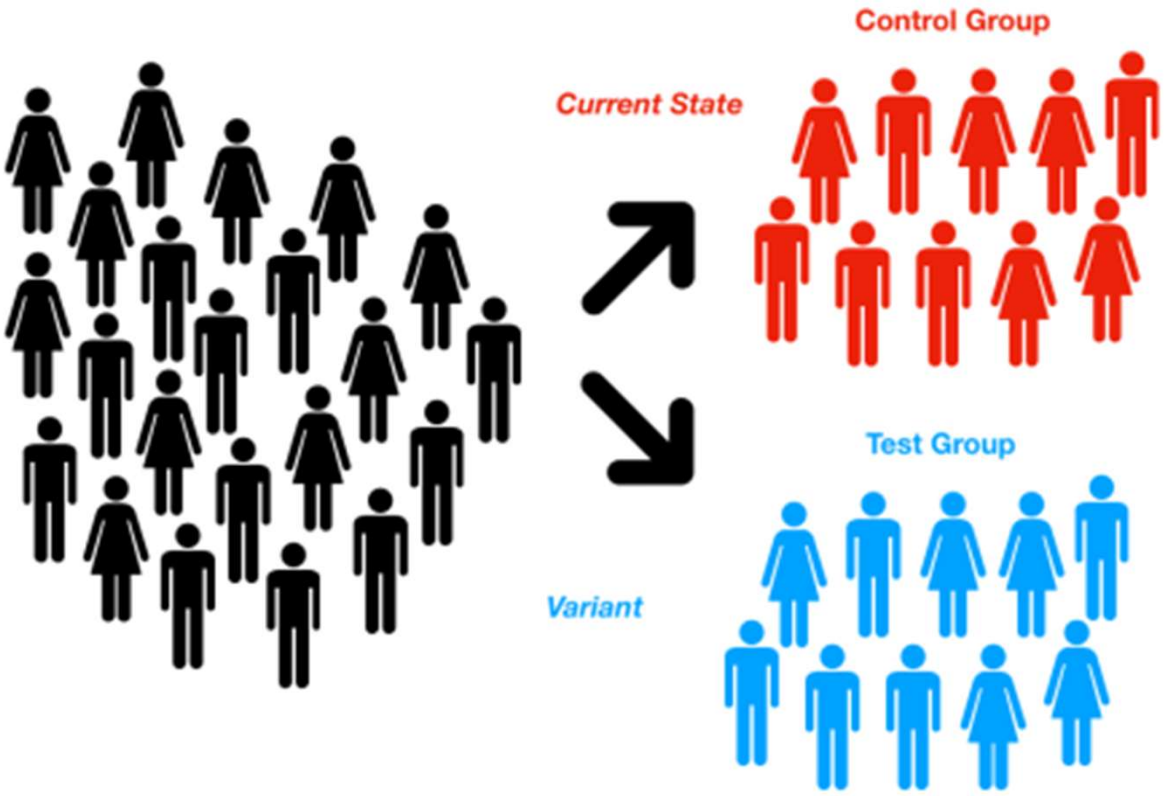
El uplift de una persona nunca se puede observar.

A cada cliente o le mandas la campaña o no se la mandas. El otro resultado pertenece a un universo que no existe, así que **no hay etiqueta de uplift que aprender**.

La salida: no recuperamos el uplift de *una persona*, sino el de **personas como ella**. Para eso los dos grupos tienen que ser comparables, y lo único que garantiza eso es el azar.

Experimentar con clientes reales

- Si solo miras a tus clientes YA contactados (sin comparar con nadie), no puedes saber si compraron POR el contacto o si iban a comprar de todos modos, estás viendo correlación, no **causalidad**
- La asignación al azar (coin-flip: mitad tratamiento, mitad control) es lo que resuelve esto: como la asignación es aleatoria, las dos mitades son **estadísticamente parecidas** en todo lo demás (edad, gasto histórico, lo que sea), la ÚNICA diferencia sistemática entre los dos grupos es si recibieron el contacto o no
- Eso permite aproximar el contrafactual de forma indirecta: en vez de preguntar **"¿qué le hubiera pasado a ESTE cliente sin contacto?",** preguntas **"¿qué le pasó, en promedio, a clientes PARECIDOS que no fueron contactados?"** , el grupo de control hace de doble/sustituto
- Sin ese grupo de control, **no tienes manera de aislar el efecto del contacto de todo lo demás que ya distingue a un cliente que compra de uno que no**



Por qué el grupo de control no es opcional

Es caro: dejas de contactar a gente que podría comprar. Y aun así es obligatorio.

Sin control

Contactas a los de más riesgo. El 40% vuelve a comprar.

Reportas: "la campaña recuperó al 40%".

No sabes si ese 40% habría vuelto igual. La cifra no significa nada.

Con control

Tratamiento: vuelve el 40%. Control: vuelve el 34%.

Reportas: "la campaña recuperó 6 puntos".

Esos 6 puntos sí son tuyos. Los otros 34 iban a ocurrir solos.

Cuánto control reservar. Un holdout del 10% basta para medir el efecto promedio. Para *modelar* uplift hace falta mucho más, nosotros usamos 50/50, porque estimar una diferencia por subgrupo consume una cantidad de datos que sorprende a casi todo el mundo.

Uplift, en una línea

$$\text{uplift}(\text{cliente}) = P(\text{compra} \mid \text{lo contacto}) - P(\text{compra} \mid \text{no lo contacto})$$

No es la probabilidad de que compre. Es **cuánto cambia** esa probabilidad por haberlo contactado.

Modelo de churn

Ordena por riesgo

Contesta: ¿quién se va?

Modelo de propensión

Ordena por probabilidad de responder

Contesta: ¿quién compra tras la campaña?

Modelo de uplift

Ordena por efecto causal

Contesta: ¿a quién muevo yo?

El de propensión también se equivoca: un Sure Thing tiene altísima probabilidad de comprar tras la campaña, y uplift cero

Tres formas de estimar Uplift

S-LEARNER

Un modelo, con el tratamiento como variable

Predices dos veces: con tratado=1 y con tratado=0. La diferencia es el uplift.

Riesgo: si el modelo decide que esa variable aporta poco, la ignora y el uplift se aplana a cero.

T-LEARNER

Dos modelos, uno por grupo

Uno aprende de los tratados, otro del control. El del control reconstruye el universo paralelo.

Riesgo: los errores de los dos modelos se suman al restar.

TRANSFORMACIÓN DE CLASE

Un truco algebraico

Defines Z = 1 si (tratado y compró) o (control y no compró). Entonces uplift = 2·P(Z=1) − 1.

Riesgo: exige asignación 50/50, o hay que ponderar.

El truco de la transformación de clase convierte un problema causal en una clasificación normal. Z vale 1 justo cuando el cliente se comportó **Pros** de que la campaña sirva. Lo van a programar en el laboratorio: son cuatro líneas.

Lai (2006) y Jaskowski & Jaroszewicz (2012) para la transformación de clase

Breakout Room # 3 – Identificar los 4 cuadrantes

Diríjase con su grupo a su breakout room, y siga las instrucciones, una vez terminadas reporte sus resultados del churn.

Objetivo:

- Detectar a los clientes que están en los cuatro cuadrantes según un experimento de control y tratamiento **previo.**
- Si solo podemos ofrecer descuentos al 30% ¿Lograremos ver en cuales es necesario invertir?
  - ¿Qué regla dejó más valor incremental total: por riesgo o por uplift?
  - .Miren la composición del 30% que targetea "por riesgo" ,¿cuántos Sleeping Dogs se colaron ahí? Eso es exactamente el costo de confundir "en riesgo" con "vale la pena contactar".
  - Con su propia tabla del Paso 4 en la mano: **¿en qué cuadrante es necesario invertir, y en cuál definitivamente NO?**

Sleeping Dogs: la campaña que ahuyenta

El cuadrante que nadie busca porque nadie cree que exista

El recordatorio fatal

Un correo de "te extrañamos" le recuerda a alguien que lleva meses pagando algo que no usa. Cancela.

El cliente premium molesto

Va poco, gasta bien y le gusta el ritual. Recibir un cupón agresivo le dice que es un número en una base de datos.

La fatiga de notificaciones

Un push de más y desactiva las notificaciones, o borra la app. Pierdes el canal para siempre.

En nuestro experimento de Starbucks los Sleeping Dogs son el **4.8% de la base**, y contactar a cada uno destruye

−$1.48 por cliente

Un modelo de uplift no se evalúa con AUC

El AUC mide si acertaste **el resultado**. Aquí no quieres acertar quién compra: quieres acertar **a quién moviste**. Y como el uplift verdadero no se observa en nadie, no hay nada contra qué calcular un AUC.

Curva Qini

Si ordeno por uplift predicho y contacto al x% de arriba, ¿cuántas compras incrementales consigo?

Tabla por deciles

¿El uplift real baja de arriba abajo? Si no baja, el modelo no está ordenando nada.

Valor de la política

Con esta regla de targeting, ¿cuánto dinero gano o pierdo de verdad?

Las tres se calculan comparando tratados contra control dentro de cada grupo, nunca contra una etiqueta de uplift

Coeficiente Qini

- Es un solo número que resume **"¿qué tan bueno es mi modelo de uplift para ordenar a los clientes?"** asi como el AUC resume qué tan bueno es un modelo de churn.
- Se construye ordenando a TODOS los clientes **de mayor a menor uplift estimado** (los que el modelo cree más persuadibles van primero)
- Después caminas esa lista de **arriba hacia abajo**, y en cada punto comparas: de los que ya pasaste, ¿cuántos tratados respondieron vs. cuántos de control respondieron?, esa diferencia acumulada es la curva Qini
- El coeficiente es el **ÁREA entre esa curva y la línea de "targeting al azar" (la diagonal),** mientras más área, mejor distingue el modelo a los persuadibles de los demás
- Un coeficiente Qini alto significa: "si sigo el orden que me da el modelo**, contactar a los primeros de la lista genera mucho más valor incremental que contactar al azar**"
- Un coeficiente cercano a cero significa que el modelo no está haciendo mejor trabajo que **tirar una moneda para decidir a quién contactar**

La curva Qini, explicada con manzanas

Antes de leer la curva real, construyámosla paso a paso

PASO 1 — LA CANASTA MEZCLADA



🍎 = cliente al que SÍ le diste el descuento (tratado) · 🍏 = cliente al que NO le diste el descuento (control). Mezclados al azar, como en el experimento real.

PASO 2 — EL MODELO LAS REORDENA

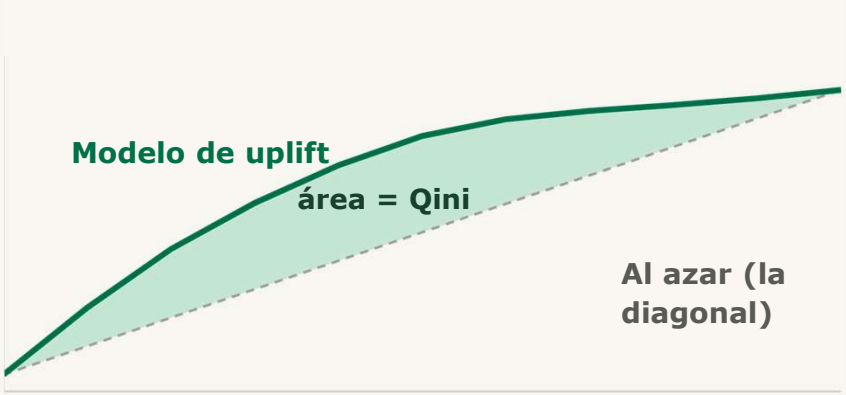


El modelo de uplift ignora si es 🍎 o 🍏 y ordena TODAS las manzanas de "más persuadable" a "menos persuadable". Las dos primeras manzanas son su apuesta más fuerte, sin importar a qué grupo pertenecen.

El orden lo decide el score de uplift predicho, nunca el grupo (tratado o control) al que perteneció cada cliente

Paso 3 — caminas la fila y cuentas

En cada punto: de las 🍎 que ya pasaste, ¿qué % compró? De las 🍏 que ya pasaste, ¿qué % compró? Restas, y acumulas.



manzanas recorridas, ordenadas por el modelo →

Si el modelo no sirve

La curva verde cae encima de la diagonal gris. Área ≈ 0.

Si el modelo ordena bien

Las primeras manzanas (las más "jugosas") muestran mucha más diferencia 🍎 vs 🍏 que las últimas. La curva se separa de la diagonal. Esa área es el **coeficiente Qini**.

La diferencia (% compró entre 🍎 − % compró entre 🍏), acumulada a medida que avanzas, nunca manzana por manzana

Breakout Room # 4 – Qini y Deciles

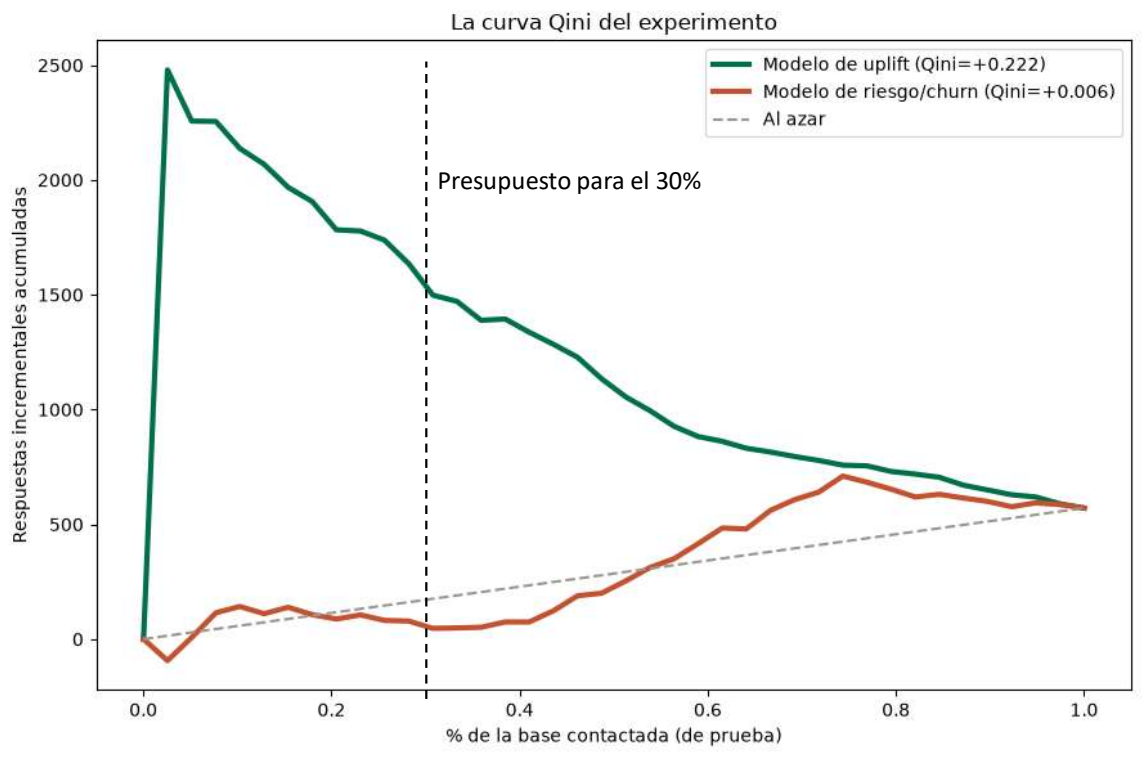
Diríjase con su grupo a su breakout room, y siga las instrucciones, una vez terminadas reporte sus resultados del churn.

Objetivo:

- Construir la curva Qini y la tabla de deciles para comparar dos formas de ordenar a los 14,000 clientes del experimento , por **riesgo/churn** y por **uplift(T-learner)**, y ver cuál de las dos sirve de verdad para decidir a quién contactar.
  - ¿El coeficiente Qini del modelo de riesgo/churn es mayor, menor o parecido al del modelo de uplift? ¿Qué dice eso sobre usar un modelo de churn para decidir a quién contactar?
  - Miren la tabla de deciles: ¿hay algún decil donde lo predicho y lo real se alejan mucho? Con ~420 clientes por decil, ¿qué tan confiables son esos números?
  - Si tuvieran que explicarle a alguien de negocio qué es el coeficiente Qini en una frase, ¿qué dirían?

La curva Qini del experimento

Compras incrementales acumuladas según a qué porcentaje de la base contactes



Coeficiente Qini · uplift

0.222

Coeficiente Qini · churn

+0.006

Cero es repartir al azar. Negativo significa ordenar al revés: contactar primero a los peores.

¿El modelo ordena de verdad?

Deciles por uplift predicho, contra el uplift real medido comparando tratados y control dentro de cada decil

Decil	Uplift predicho	Uplift real
1 (mejor)	+0,223	+0,188
2	+0,151	+0,170
3	+0,110	+0,091
4	+0,078	+0,100
5	+0,055	+0,033
6	+0,039	−0,045
7	+0,023	+0,027
8	+0,008	+0,040
9	−0,007	−0,002
10 (peor)	−0,056	−0,004

Los tres primeros deciles

Predicho y real coinciden de cerca. Ahí están los Persuadables, y ahí va el presupuesto.

El decil 6 se sale del patrón

Predice +0,039 y mide −0,045. No lo escondas: con 1.400 clientes por decil, el intervalo de confianza es ancho.

Una escalera perfecta sería motivo de sospecha, no de celebración.

T-learner · 14.000 clientes de prueba

Conclusiones finales

El experimento: Starbucks Rewards

Campaña de reactivación con asignación aleatoria.

Base de clientes

40,000

Mitad tratamiento, mitad control

La oferta

$5

Push con descuento en la próxima compra

Ventana de medición

60 días

¿Volvió a comprar? ¿Cuánto gastó?

La economía de contactar a un cliente

valor = uplift × margen si vuelve − **$5 × P(vuelve | tratado)** − $0,05 de envío

El término naranja es la clave: el descuento se paga **también a quien iba a comprar de todos modos**. Esa es la canibalización que ningún modelo de churn ve.

Caso Hipotetico – Contactemos a todos…

Grupo tratamiento

63.3%

volvió a comprar

Grupo control

56.8%

volvió a comprar

Efecto promedio

+6.5 pp

estadísticamente sólido

"La campaña funcionó. Subió la retención 6.5 puntos. **Lancémosla a toda la base.**"

Lo que ese +6,5% esconde

La composición real de la base. En la vida real es invisible; aquí la conocemos porque los datos son simulados.

Tipo de cliente	% base	Uplift real	Valor de contactarlo
Sure Things	48,1%	+0,004	−$4,73
Persuadables	22,7%	+0,287	+$7,91
Lost Causes	22,0%	+0,018	+$0,13
Sleeping Dogs	7,1%	−0,163	−$5,76

Casi la mitad de la base

destruye valor al ser contactada

Solo un grupo deja dinero

y es el 22,7%

Ejemplos Reales

Banco anonimo en USA

Commentary by Mark Smith, Executive Vice President, Portrait Software

A large successful American bank that had recently launched a new high-margin product was aiming to increase new product bookings. Should the bank mail all its customers to increase sales of the new product and incur a high mailing cost while still providing a positive return on mailings? Or could the bank increase incremental sales while reducing mailing costs by focusing its mailing on those customers best influenced by the marketing?

Resultados

	Conversión	Utilidad por cliente
Control	15.07%	$5.26
Contactar a todos	18.04%	**$5.18**
Optimizado por uplift	17.32%	**$5.46**

https://tdwi.org/articles/2007/10/18/case-study-top-retail-bank-more-than-doubles-campaign-profitability-using-latest-umt.aspx

Ejemplos Reales
Consultoría

https://cmr.berkeley.edu/2025/11/to-treat-or-not-to-treat-five-lessons-learned-from-using-uplift-modeling-to-optimize-marketing-campaigns/

Cuando los costos del tratamiento son particularmente altos

El modelado de impacto también es superior a los métodos tradicionales cuando los costos de atender a los clientes son particularmente altos, como en las campañas offline dirigidas a clientes mediante correo impreso, telemarketing y ventas directas puerta a puerta. Si se calculan los costos de impresión, el franqueo, el costo del personal de telemarketing para realizar llamadas, etc., se puede apreciar fácilmente el enorme despilfarro de dinero que esto implica, una cantidad que no se puede compensar con el aumento de ingresos, incluso si la intervención modifica el comportamiento del cliente.

La principal ventaja del modelado de impacto en estos entornos radica en la capacidad de diferenciar entre distintos tipos de clientes y, por lo tanto, reducir drásticamente el número de ellos a los que dirigirse, mientras que los métodos tradicionales simplemente no logran distinguir entre *lo seguro y lo persuasible* , ni entre las *causas perdidas* y los problemas sin *resolver* .

En una colaboración, redujimos el número de clientes objetivo en un 80 % y los costes de segmentación de 400 000 dólares a 80 000 dólares, al tiempo que aumentamos el número de renovaciones de contratos en comparación con la segmentación de todos los clientes (porque se molestó a muchos menos *Sleeping Dogs*).

Ejemplos Reales

Uber

Uber: experimento de promoción para adoptar un producto nuevo

Un experimento con un grupo de control y dos de tratamiento (600K observaciones de entrenamiento, 800K de prueba, 139 variables). Conversión de 0.53% en control, 1.39% en el tratamiento 1 y 2.18% en el tratamiento 2. Los modelos que optimizan **valor neto** (descontando el costo de la promoción) superaron a los modelos estándar y a los grupos originales del experimento.

https://arxiv.org/abs/1908.05372

Conclusiones

El costo oculto de dar descuento a todos

El descuento a todos tiene **tres costos que no salen en el reporte de conversión**:

- Pagas el cupón a los Sure Things, que habrían comprado igual.
- Provocas efecto negativo en los Sleeping Dogs.
- Acostumbras al cliente a esperar la promoción.

Los casos reales lo muestran. En el retailer del artículo de California Management Review, contactar a todos subió la conversión (15.07% → 18.04%) pero bajó la utilidad por cliente por debajo del control ($5.26 → $5.18). El targeting por uplift la subió a $5.46.

Conclusiones

Cómo medir el éxito de verdad

Una campaña no se mide por cuántos compraron, sino por **cuántos compraron por la campaña**. Eso exige un grupo de control aleatorio, porque nadie observa el contrafactual.

Mide en tres capas:

- **Incrementalidad:** la diferencia entre tratamiento y control, no solo la tasa de respuesta.
- **Valor neto:** margen incremental menos costo del cupón y del envío.
- **Calidad del ranking:** AUC y Precision@k para churn; Qini para uplift.

Una campaña con buena conversión **puede perder dinero**.

Conclusiones

La ética de a quién le damos el descuento

Efectos del Uplift reales:

- El uplift tiende a no dar descuento al **cliente fiel** (Sure Thing), porque ya compra. Es eficiente, pero esa persona paga precio completo mientras otro recibe oferta.
- Si el criterio es sensible al cliente que amenaza con irse, **puede incentivar ese comportamiento**.
- Una salida razonable **es combinar el uplift con reglas explícitas**: recompensas de lealtad visibles, topes de uso, y un porcentaje de control que no se toca.

Conclusiones

Churn y calidad de servicio

- El modelo de churn te dice quién se va, pero no por qué. Muchas veces la causa **es una mala experiencia**, y un descuento no la arregla.
- Un cliente molesto por un mal servicio quizá **necesita una solución, no un cupón**.
- Cuando sea posible, conviene **cruzar el riesgo de churn con indicadores de servicio** (satisfacción, tiempos de resolución, reclamos repetidos) para entender las causas de la salida. La correlación indica dónde mirar, pero para confirmar que mejorar el servicio reduce el churn hay que probarlo con un experimento con grupo de control.

